

# Kapitel 5



## Bäume

Ein **Baum** (tree) ist ein spezieller Graph, der eine hierarchische Struktur über eine Menge von Objekten definiert


Intuitives Vorstellungsmodell - Nicht-lineare Datenstruktur

Anwendungen

Repräsentieren Wissen, Darstellung von Strukturen, Abbildung von Zugriffspfaden, Analyse hierarchischer Zusammenhänge, ...

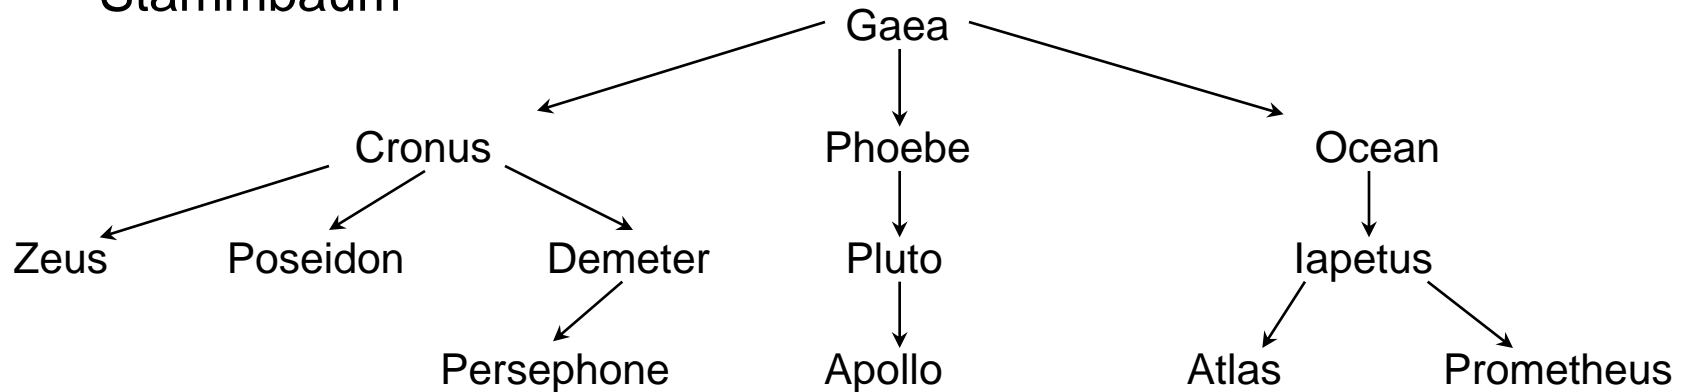


## Prozessorfamilien



Spezialfall  
Liste

## Stammbaum



Ein **Baum** besteht aus einer Menge von **Knoten**, die durch **gerichtete Kanten** verbunden sind

Ein **Pfad** oder **Weg** ist eine Liste sich unterscheidender Knoten, wobei aufeinander folgende Knoten durch eine Kante verbunden sind

## Definierende Eigenschaft eines Baumes

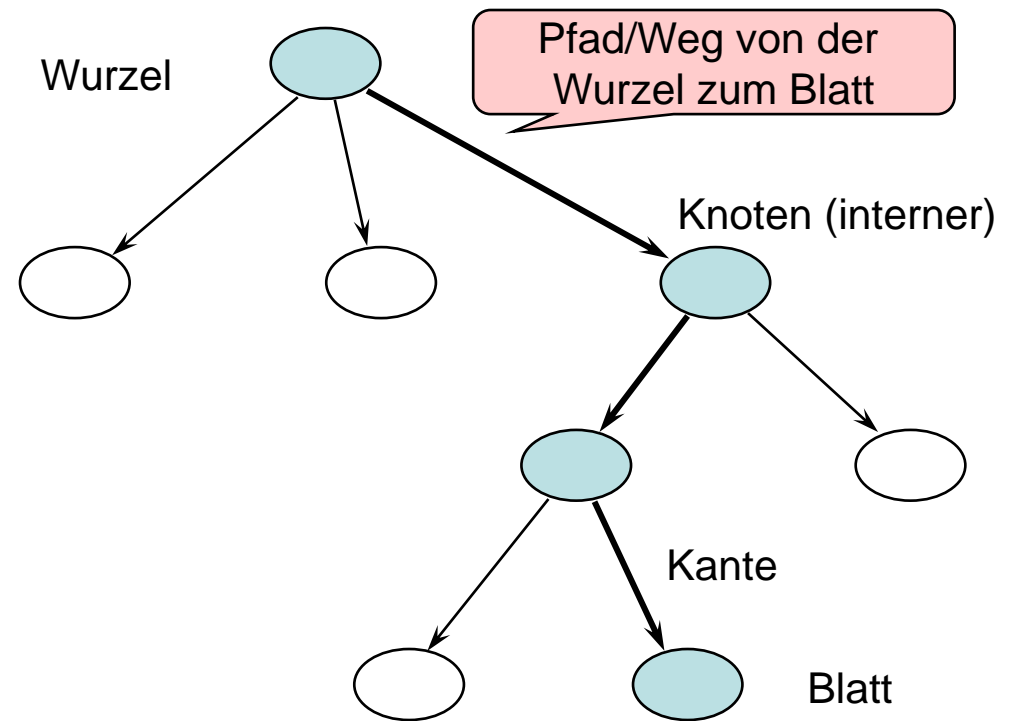
- Es gibt genau einen Pfad der 2 Knoten miteinander verbindet
- jeder Knoten hat nur einen direkten Vorgänger
- alle Vorgänger eines Knoten sind von ihm selbst verschieden

Ein Baum enthält daher **keine Kreise**, d.h. einen Pfad bei dem der Startknoten gleich dem Endknoten ist



Die **Wurzel** (**root**) ist der einzige Knoten mit nur wegführenden Kanten

Ein **Blatt** (**leaf**) ist ein Knoten von denen keine Kanten wegführen




Knoten, in die eine Kante hineinführt und von denen Kanten wegführen, heißen **interne Knoten**



## Gültige Bäume



## Ungültige Bäume



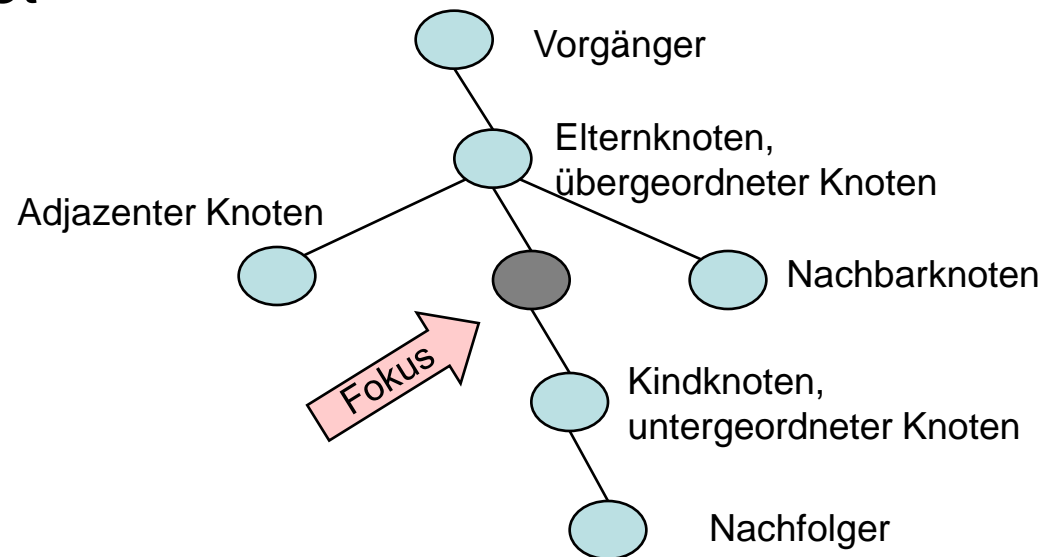
- Es gibt genau einen Pfad der 2 Knoten miteinander verbindet
- jeder Knoten hat nur einen direkten Vorgänger
- alle Vorgänger eines Knoten sind von ihm selbst verschieden

Jeder Knoten (mit Ausnahme der Wurzel) hat genau einen Knoten über sich, den man als **Elternknoten** oder **übergeordneten Knoten** bezeichnet

Die Knoten direkt unterhalb eines Knotens heißen **Kindknoten** oder **untergeordnete Knoten**

Transitive Eltern werden als **Vorgänger** bzw. transitive Kinder als **Nachfolger** bezeichnet


Räumlich nebeneinanderliegende Knoten auf derselben Tiefe heißen **adjazent** oder **Nachbarn**



Ein einzelner Knoten ohne Kanten ist ein Baum

Seien  $T_1, \dots, T_k$  ( $k > 0$ ) Bäume ohne gemeinsame Knoten. Die Wurzeln dieser Bäume seien  $r_1, \dots, r_k$ . Ein Baum  $T_0$  mit der Wurzel  $r_0$  besteht aus den Knoten und Kanten der Bäume  $T_1, \dots, T_k$  und neuen Kanten von  $r_0$  zu den Knoten  $r_1, \dots, r_k$

Der Knoten  $r_0$  ist dann die neue Wurzel und  $T_1, \dots, T_k$  sind **Unterbäume** von  $T_0$






Die **Länge eines Weges** zwischen 2 Knoten entspricht der Anzahl der Kanten auf dem Weg zwischen den beiden Knoten

Die **Höhe eines Knoten** ist die Länge des längsten Weges von diesem Knoten zu den erreichbaren Blättern

Die **Tiefe eines Knoten** ist die Länge des Weges zur Wurzel

Die **Höhe eines Baumes** entspricht der Höhe der Wurzel



**Parsierungsbäume (parse trees)** analysieren Anweisungen bzw. Programme einer Programmiersprache bezüglich einer gegebenen Grammatik

Eine Grammatik definiert Regeln, wie und aus welchen Elementen eine Programmiersprache aufgebaut ist

Beispiel: C++ (Ausschnitt)

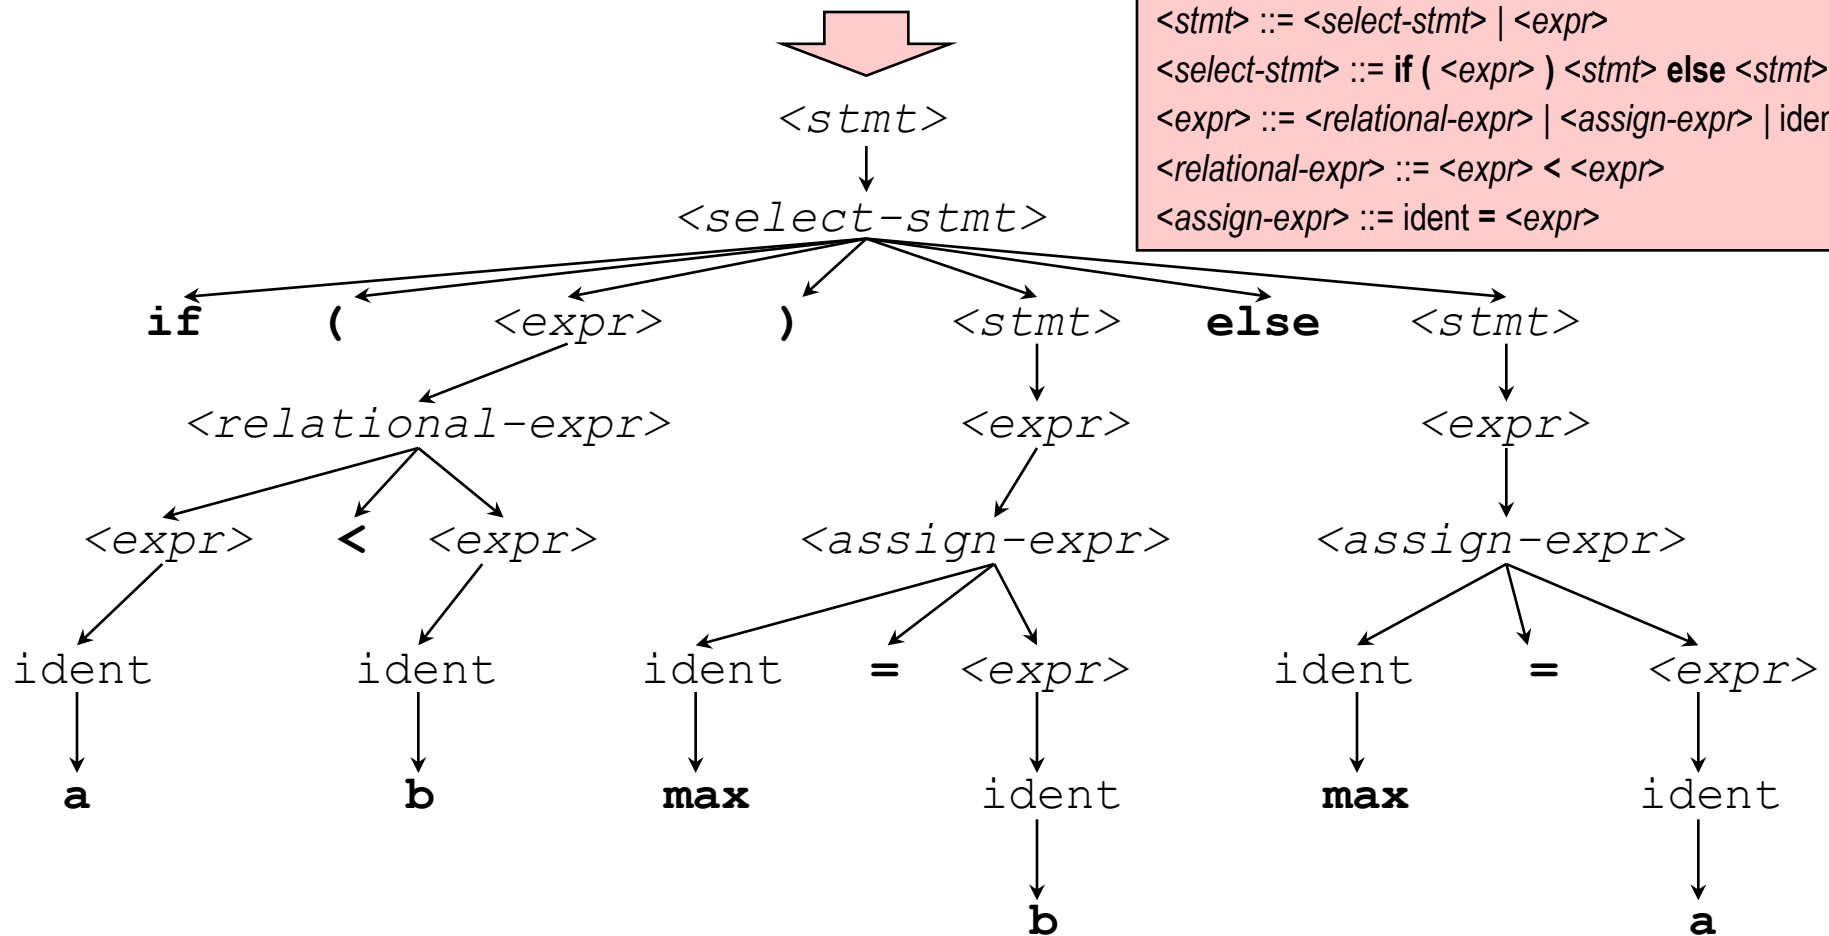
```
<stmt> ::= <select-stmt> | <expr>
<select-stmt> ::= if ( <expr> ) <stmt> else <stmt>
<expr> ::= <relational-expr> | <assign-expr> | ident
<relational-expr> ::= <expr> < <expr>
<assign-expr> ::= ident = <expr>
```

<code>&lt;stmt&gt;</code>	Nonterminal Symbole (werden aufgelöst)
<code>if, ident</code>	Terminalsymbole (nicht mehr aufgelöst)
<code>::=,  </code>	Grammatiksymbolik

# Beispiel Parse Tree (2)

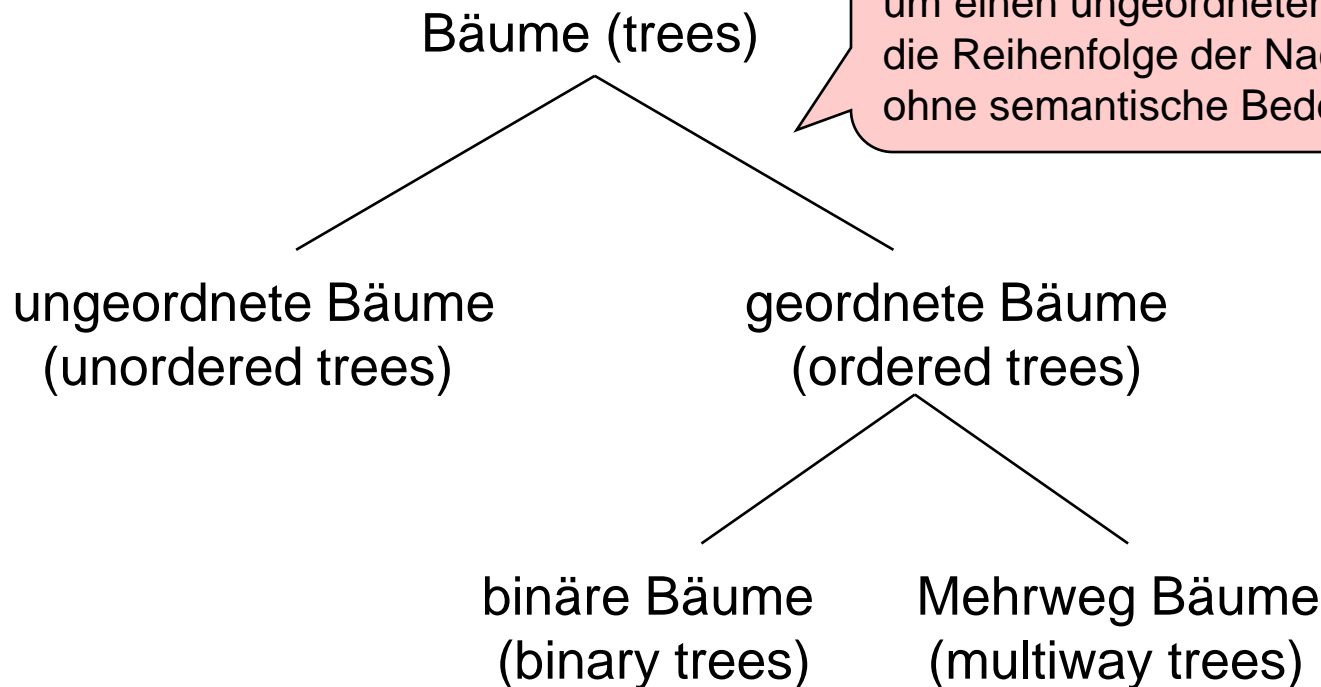


**if (a < b) max = b else max = a**



Die **Ordnung** legt die Position der Nachfolger eines Knotens in der grafischen Darstellung des Baumes fest (Knoten A links von Knoten B)


D.h. für die Kinder jedes Knotens ist eine Ordnungsrelation definiert




Bei diesem Baum handelt es sich um einen ungeordneten Baum, da die Reihenfolge der Nachfolger ohne semantische Bedeutung ist

**Binäre Bäume** sind geordnete Bäume, in denen jeder Knoten maximal 2 Kinder hat und die Ordnung der Knoten mit links und rechts festgelegt ist


Binärer Baum mit 2 Kindern



Binärer Baum mit rechtem Kind (right child)



Binärer Baum mit linkem Kind (left child)



Binärer Baum ohne Kind (Blatt)



Häufiger Einsatz in Algorithmen

Effiziente Manipulationsalgorithmen


Zusammenhang zw. Anzahl der Elemente und der Höhe



Höhe 0

1 Knoten


1 Blatt



Höhe 1

3 Knoten

2 Blätter




Höhe 2

7 Knoten

4 Blätter

In jeder neuen Ebene wird im optimalen Fall die Anzahl der Blätter verdoppelt

Entartung möglich: Jeder Knoten hat genau ein Kind → entspricht linearer Liste



## Leerer binärer Baum

Binärer Baum ohne Knoten

## Voller binärer Baum

Jeder Knoten hat keine oder 2 Kinder

## Perfekter binärer Baum

Ein voller binärer Baum bei dem alle Blätter dieselbe Tiefe besitzen

## Kompletter binärer Baum

Ein perfekter binärer Baum mit der Ausnahme, dass die Blattebene nicht vollständig, dafür aber von links nach rechts, gefüllt ist


## Höhen-balanzierter binärer Baum

Für jeden Knoten ist der Unterschied der Höhe des linken und rechten Kindes maximal 1

## Full binary tree

Jeder Knoten im Baum hat keine oder genau 2 Kinder.


Mit anderen Worten, kein Knoten besitzt nur 1 Kind





## Perfect binary tree

Ein voller binärer Baum (alle Knoten haben keine oder genau 2 Kinder)  
bei dem alle Blätter dieselbe Tiefe besitzen.



## Eigenschaften

Frage: welche Höhe  $h$  muss ein perfekter binärer Baum haben um  $n$  Blätter zu besitzen

In jeder Ebene Verdoppelung, d.h.  $2^h = n$

$$h * \log 2 = \log n$$

$$h = \log_2 n = \lg n$$

Ein perfekter binärer Baum der Höhe  $h$  besitzt  $2^{h+1}-1$  Knoten  
davon sind  $2^h$  Blätter

Beweis mit vollständiger Induktion


Zusammenhang zwischen Knoten/Blätter und Höhe:

$O(n)$  Knoten/Blätter :  $O(\log n)$  Höhe

wichtigste  
Eigenschaft  
von Bäumen

## Complete binary tree

Ein kompletter binärer Baum ist ein perfekter binärer Baum mit der Ausnahme, dass die Blattebene nicht vollständig, dafür aber von links nach rechts, gefüllt ist




## Eigenschaft

Ein kompletter binärer Baum mit  $n$  Knoten hat eine Höhe von maximal  $h = \lfloor \log_2 n \rfloor$

## Height-balanced binary tree

Für jeden Knoten ist der Unterschied der Höhe des linken und rechten Kindes maximal 1

Dies garantiert, dass lokal für jedes Kind die Balanzierungseigenschaft relativ gut erfüllt ist, global aber die gesamten Baumdifferenzen größer sein können → einfachere Algorithmen



## Traversieren eines Baumes bezeichnet das systematische Besuchen aller seiner Knoten

Unterschiedliche Methoden unterscheiden sich in der Reihenfolge der besuchten Knoten


Mögliche Reihenfolgen

A, B, C

B, A, C


B, C, A

...



Systematische Auswertung eines mathematischen Ausdrucks  
Ein mathematischer Ausdruck kann in Form eines Expression Trees angegeben werden

$(20 / 5) + 3$



Blätter repräsentieren Operanden (Zahlenwerte), interne Knoten Operatoren

Auswertung des Ausdrucks läuft von den Blättern zur Wurzel  
Baumdarstellung erspart Klammernotation

Traversierungsalgorithmen bestehen prinzipiell aus 3 verschiedenen Schritten

- Bearbeiten eines Knotens (process node)

- Rekursiv besuchen und bearbeiten des linken Kindes (visit left child)

- Rekursiv besuchen und bearbeiten des rechten Kindes (visit right child)

Durch unterschiedliches Anordnen der 3 Schritte unterschiedliche Reihenfolgen

3 Bearbeitungsreihenfolgen interessant

- Preorder Traversierung

- Postorder Traversierung

- Inorder Traversierung

## Algorithmus

```
preorder(node) {  
    if(node != 0) {  
        process(node)  
        preorder(left child)  
        preorder(right child)  
    }  
}
```

Besucht die Knoten im Baum in *Prefix-Notation-Reihenfolge*

(Operator, Operand<sub>1</sub>, Operand<sub>2</sub>)

Faustregel


Knoten bearbeiten beim 1. Besuch

Anwendung

LISP, Assembler

Beispiel

20/5+3



Process-Reihenfolge: A B C D E

Notation-Reihenfolge: + / 20 5 3



## Algorithmus

```
postorder(node) {  
    if(node != 0) {  
        postorder(left child)  
        postorder(right child)  
        process(node)  
    }  
}
```

## Postfix-Notation-Reihenfolge

(Operand1, Operand2, Operator)

## Faustregel


Knoten bearbeiten beim letzten  
Besuch

## Anwendung

Invers Polish Notation, HP  
Taschenrechner, FORTH

## Beispiel

20/5+3



Process-Reihenfolge: C D B E A

Notation-Reihenfolge: 20 5 / 3 +

## Algorithmus

```
inorder(node) {  
    if(node != 0) {  
        inorder(left child)  
        process(node)  
        inorder(right child)  
    }  
}
```

## Infix-Notation-Reihenfolge

(Operand<sub>1</sub>, Operator, Operand<sub>2</sub>)

## Faustregel


Knoten bearbeiten beim 2. oder letzten  
Besuch

## Anwendung

einfacher algebraischer Taschen-  
rechner (ohne Klammern)

## Beispiel

20/5+3



Process-Reihenfolge: C B D A E

Notation-Reihenfolge: 20 / 5 + 3

In einem Binärbaum besitzt jeder (interne) Knoten eine linke und eine rechte Verbindung, die auf einen Binärbaum oder einen externen Knoten verweist (voller binärer Baum)

Verbindungen zu externen Knoten heißen Nullverbindungen, externe Knoten besitzen keine weiteren Verbindungen

Ein binärer Suchbaum (binary search tree, BST) ist ein Binärbaum, bei dem jeder interne Knoten einen Schlüssel besitzt

externe Knoten besitzen keine Schlüssel


Externe Knoten enthalten die verwaltete Information, i.e. Datenspeicher (wird hier nicht weiter behandelt)

Auf den Schlüsseln ist eine lineare Ordnung “<” definiert

Wenn  $x$  und  $y$  verschieden sind, so gilt  $x < y$  oder  $y < x$ ; ist  $x < y$  und  $y < z$ , dann gilt auch  $x < z$

Für jeden internen Knoten gilt, dass alle Werte der Nachfolger im linken Unterbaum kleiner als der Knotenwert und die Werte der Nachfolger im rechten Unterbaum größer als der Knotenwert sind

Annahme: keine doppelten Werte



Verwaltung beliebig großer Datenbestände

dynamische Struktur

Effiziente Verwaltung

Aufwand proportional zur Höhe des Baumes (Erwartungswert!) und nicht zur Anzahl der Elemente

Einfügen, Zugriff und Löschen im Durchschnitt von  $O(\log n)$

Signifikante Verbesserung im Vergleich zum linearen Aufwand  $O(n)$  bei Liste

Zugriff auf Elemente in sortierter Reihenfolge durch inorder Traversierung

## Erstellen

Erzeugen eines leeren Suchbaumes

## Einfügen

Einfügen eines Elementes in den Baum unter Berücksichtigung der  
Ordnungseigenschaft

## Suche

Test auf Inklusion

## Löschen

Entfernen eines Elementes aus dem Baum unter Erhaltung der  
Ordnungseigenschaft


## Ausgabe

Ausgabe aller Elemente in sortierter Reihenfolge

...

```
typedef int ItemType;
class SearchTree {
    class node {
    public:
        ItemType info;
        node * leftchild, * rightchild;
        node(ItemType x, node * l, node * r) {info=x; leftchild=l; rightchild=r;}
    };
    typedef node * link;
    link root;
    void AddI(ItemType);
    void AddR(link&, ItemType);
    bool MemberI(ItemType);
    bool MemberR(link, ItemType);
    void PrintR(link, int);
public:
    SearchTree(){root = 0;}
    void Add(ItemType);
    int Delete(ItemType);
    bool Member(ItemType);
    void Print();
};
```

Einfachheitshalber im  
**node** alles **public**




Beim Suchen eines Schlüssels wird ein Pfad von der Wurzel abwärts verfolgt

Bei jedem internen Knoten wird der Schlüssel  $x$  mit dem Suchschlüssel  $s$  verglichen


Falls  $x = s$  liegt ein Treffer vor, falls  $s < x$  suche im linken Teilbaum, sonst im rechten

Wenn man einen externen Knoten erreicht, war die Schlüssel-Suche „erfolglos“

Erfolgreiche Suche (z.B. 11)



Erfolglose Suche (z.B. 13)





```
bool SearchTree::MemberI(ItemType a) {  
    if(root) {  
        link current = root;  
        while(current) {  
            if(current->info == a) return true;  
            if(a < current->info)  
                current = current->leftchild;  
            else  
                current = current->rightchild;  
        }  
    }  
    return false;  
}  
  
bool SearchTree::Member(ItemType a) {  
    return MemberI(a);  
}
```


Aufruf:

SearchTree t;

...

t.Member(7);

Verzweigung auf  
current->leftchild,  
da  $a < \text{current->info}$   
(d.h.  $7 < 12$ )



return true, da  $\text{current->info} == a$  (gefunden!)

```
bool SearchTree::MemberR(link h, ItemType a) {
    if(!h) return false;
    else {
        if(a == h->info) return true;
        if(a < h->info)
            return MemberR(h->leftchild, a);
        else
            return MemberR(h->rightchild, a);
    }
}


bool SearchTree::Member(ItemType a) {
    return MemberR(root, a);
}

Aufruf:
SearchTree t;
...
t.Member(7);
```


Das Einfügen entspricht einer erfolglosen Suche und dem Anfügen eines neuen Knotens an der Nullverbindung wo die Suche endet (anstelle des externen Knotens)

Einfügen 13

Suche



Knoten anfügen



## Ähnlich dem Einfügen in eine Liste (2 Hilfszeiger)

```
void SearchTree::AddI(ItemType a) {
```

```
    if(root) {
```

```
        link current = root;
```

```
        link child;
```

```
        while(1) {
```

```
            if(a == current->info) return;
```

```
            if(a < current->info) {
```

```
                child = current->leftchild;
```

```
                if(!child) {current->leftchild = new node(a, 0, 0); return;}
```

```
            } else {
```

```
                child = current->rightchild;
```

```
                if(!child) {current->rightchild = new node(a, 0, 0); return;}
```

```
            }
```

```
            current = child;
```

```
        }
```

```
    } else {
```

```
        root = new node(a, 0, 0);
```

```
        return;
```

```
    }
```

```
void SearchTree::Add(ItemType a) {  
    ...  
    AddI(a);  
}
```


Hilfszeiger:  
**current, child**

Aufruf:

```
    SearchTree t;
```

```
    ...
```

```
    t.Add(7);
```



```
void SearchTree::AddR(link& h, ItemType a) {
    if(!h) {h = new node(a, 0, 0); return;}
    if(a == h->info) return;
    if(a < h->info)
        AddR(h->leftchild, a);
    else
        AddR(h->rightchild, a);
}

void SearchTree::Add(ItemType a) {
    AddR(root, a);
}
```

Aufruf

```
SearchTree t;
```

...

```
t.Add(7);
```

Man beachte die Verwendung  
eines Referenzparameters  
(link&), erspart die 2  
Hilfszeiger

```
void SearchTree::PrintR(link h, int n) {  
    if(!h) return;  
    PrintR(h->rightchild, n+2);  
    for(int i = 0; i < n; i++) cout << " ";  
    cout << h->info << endl;  
    PrintR(h->leftchild, n+2);  
}
```

Inorder  
Traversierung

```
void SearchTree::Print() {  
    PrintR(root, 0);  
}
```

Aufruf

```
SearchTree t;
```

...

```
t.Print();
```

Gibt Baum um 90 Grad gegen den  
Uhrzeigersinn verdreht aus

## Der Löschvorgang unterscheidet 3 Fälle


Löschen von internen Knoten mit

(1) keinem

(2) einem

(3) zwei

internen Knoten als Kind(er)




Fälle 1 und 2 sind einfach durch Anhängen des verbleibenden Teilbaums an den Elternknoten des zu löschenden Knotens zu lösen.

Für Fall 3 muss ein geeigneter Ersatzknoten gefunden werden. Hierzu eignen sich entweder der kleinste im rechten (Inorder Nachfolger) oder der größte im linken Teilbaum (Inorder Vorgänger)


## Fall 1

Löschen von Knoten 3 durch Ersetzen des linken Kindzeigers von Knoten 7 durch den externen Knoten (hier Nullverbindung)




## Fall 2

Löschen von Knoten 15 durch Einhängen des Knoten 21 als rechtes Kind von 12






## Fall 3



Im Falle des Löschens von 12 eignen sich als Ersatz die Knoten mit den Werten 11 (größte im linken) oder 15 (der kleinste im rechten Teilbaum).

Dies resultiert in 2 möglichen Bäumen:




Somit muss der Löschvorgang für Fall 3 in zwei Teile zerlegt werden:

1. Finden eines geeigneten Ersatzknotens
2. Ersetzen des zu löschenden Knotens (was wiederum aus dem Entfernen des Ersatzknotens aus seiner ursprünglichen Position (entspricht Fall 1 oder 2) und dem Einhängen an der neuen Stelle besteht)

Erwartungswert der Einfüge- und Suchoperationen bei  $n$  zufälligen Schlüsselwerten ist ungefähr  $1,39 \lg n$

Im ungünstigsten Fall kann der Aufwand zu ungefähr  $n$  Operationen „entarten“

Beispiele für ungünstige Suchbäume



## Datenverwaltung

unterstützt Einfügen und Löschen

## Datenmenge

unbeschränkt

## Modelle

Hauptspeicherorientiert

Unterstützung komplexer Operationen

Bereichsabfragen, Sortierreihenfolge

## Laufzeit


Speicherplatz	$O(n)$
Konstruktor	$O(1)$
Zugriff	$O(\log n)$
Einfügen	$O(\log n)$
Löschen	$O(\log n)$
Sortierreihenfolge	$O(n)$

Bitte beachten:  
beträchtlicher konstanter  
Aufwand ist notwendig!

} Erwartungswert!


**Mehrwegbäume** sind Bäume mit Knoten, die mehr als 2 Kinder besitzen können

### Intervallbasierten Suchdatenstrukturen



Knoten besteht aus einer Menge von  **$m$  Schlüsselwerten**  $k_1, k_2, \dots, k_m$  und  **$m+1$  Verweisen** (Kanten)  $p_0, p_2, \dots, p_m$ , sodass für alle Schlüssel  $x_j$  im Unterbaum, der durch  $p_i$  referenziert wird, gilt  $k_i \leq x_j < k_{i+1}$  (Schlüssel liegen im Intervall  $[k_i, k_{i+1}[$ ).

### Beispiel



Interne Knoten

Externe Knoten

Ähnlich zur Suche im binären Suchbaum

Bei jedem internen Knoten mit Schlüsseln  $k_1, k_2, \dots, k_m$  und Verbindungen  $p_0, p_1, \dots, p_m$

Suchschlüssel  $s = k_i$  ( $i = 1, \dots, m$ ): Suche erfolgreich


$s < k_1$ : fortsetzen im Unterbaum  $p_0$

$k_i \leq s < k_{i+1}$ : fortsetzen im Unterbaum  $p_i$

$s \geq k_m$ : fortsetzen im Unterbaum  $p_m$

Falls man einen externen Knoten erreicht: Schlüsselsuche erfolglos

Beispiel: Suche 50




Ein **2-3-4 Baum** ist ein Mehrwegbaum mit den folgenden Eigenschaften

**Größeneigenschaft:** jeder interne Knoten hat mindestens 2 und maximal 4 Kinder

**Tiefeigenschaft:** alle externe Knoten besitzen dieselbe Tiefe

Abhängig von der Anzahl der Kinder heißt ein interner Knoten 2-Knoten, 3-Knoten oder 4-Knoten



**Satz:** Ein 2-3-4 Baum, der  $n$  interne Knoten speichert, hat (immer) eine Höhe von  $O(\log n)$

## Beweis

Die Höhe des 2-3-4 Baumes mit  $n$  internen Knoten sei  $h$

Da es mindestens  $2^i$  interne Knoten auf den Tiefen  $i = 0, \dots, h-1$  gibt und keine internen Knoten auf Tiefe  $h$ , gilt

$$n \geq 1 + 2 + 4 + \dots + 2^{h-1} = 2^h - 1$$

Daher gilt  $h \leq \log_2 (n + 1)$


$$n \geq 2^h - 1$$

$$n + 1 \geq 2^h$$

$$\log(n + 1) \geq h \log 2$$

$$h \leq \log(n + 1) / \log 2 =$$

$$\log_2(n + 1)$$




Ein neuer Schlüssel  $s$  wird im Elternknoten  $v$  des externen Knotens eingefügt, den man bei der Suche nach  $s$  erreicht hat

Die Tiefeneigenschaft des Baumes wird erhalten, aber es wird möglicherweise die Größeneigenschaft verletzt

Ein (Knoten-) Überlauf ist möglich (es entsteht ein 5-Knoten)

Beispiel: Einfügen von 30 erzeugt Überlauf





Ein Überlauf (Overflow) bei einem 5-Knoten  $v$  wird durch eine Split Operation aufgelöst

Die Kinder von  $v$  seien  $v_1, \dots, v_5$  und die Schlüssel von  $v$  seien  $k_1, \dots, k_4$


Knoten  $v$  wird durch die Knoten  $v'$  und  $v''$  ersetzt, wobei

$v'$  ein 3-Knoten mit den Schlüsseln  $k_1$  und  $k_2$  und Kindern  $v_1, v_2$  und  $v_3$ ,

$v''$  ein 2-Knoten mit Schlüssel  $k_4$  und Kindern  $v_4$  und  $v_5$  ist

Schlüssel  $k_3$  wird in den Elternknoten  $u$  von  $v$  eingefügt (dadurch kann eine neue Wurzel entstehen)

Ein Überlauf kann an die Vorgänger von  $u$  propagiert werden




Der Löschvorgang wird auf den Fall reduziert, wo der zu löschende Schlüsselwert in einem internen Knoten mit externen Knotenkindern liegt

Andernfalls wird der Schlüsselwert mit seinem Inorder Nachfolger (oder Inorder Vorgänger) ersetzt


Analog Fall 3 binäre Suchbäume

Beispiel Löschen Schlüssel 24



Durch das Löschen eines Schlüssels in einem Knoten  $v$  kann es zu einem Unterlauf (underflow) kommen

Knoten  $v$  degeneriert zu einem 1-Knoten mit einem Kind und keinem Schlüssel



Bei einem Unterlauf kann man 2 Fälle unterscheiden

Fall 1: Verschmelzen

Benachbarte Knoten werden zu einem erlaubten Knoten verschmolzen

Fall 2: Verschieben


Schlüsselwerte und entsprechende Kinder werden zwischen Knoten verschoben

## Fall 1: Verschmelzen von Knoten

Bedingung: Alle adjazenten Knoten (benachbarte Knoten auf derselben Tiefe) zum unterlaufenden Knoten  $v$  sind 2-Knoten

Man verschmilzt  $v$  mit einem/dem adjazenten Nachbarn  $w$  und verschiebt den nicht mehr benötigten Schlüssel vom Elternknoten  $u$  zu dem verschmolzenen Knoten  $v'$

Das Verschmelzen kann den Unterlauf zum Elternknoten propagieren



## Fall 2: Verschieben von Schlüsseln


Bedingung: Ein adjazenter Knoten (benachbarter Knoten auf derselben Tiefe)  $w$  zum unterlaufenden Knoten  $v$  ist ein 3-Knoten oder 4-Knoten

Man verschiebt ein Kind von  $w$  nach  $v$

Man verschiebt einen Schlüssel von  $u$  nach  $v$

Man verschiebt einen Schlüssel von  $w$  nach  $u$

Nach dem Verschieben ist der Unterlauf behoben



## Datenverwaltung

Einfügen und Löschen unterstützt

## Datenmenge

unbeschränkt

## Modelle

Hauptspeicherorientiert

Unterstützung komplexer Operationen

Bereichsabfragen, Sortierreihenfolge

## Laufzeit

Speicherplatz	$O(n)$
Verschmelzen, Verschieben	$O(1)$
Zugriff	$O(\log n)$
Einfügen	$O(\log n)$
Löschen	$O(\log n)$
Sortierreihenfolge	$O(n)$

} Garantiert!

<i>Baumvariante</i>	<i>Baumhöhe + Aufwand der Operationen</i>	<i>Balanzierungsform</i>	<i>Methode</i>
Allgemeiner Binärer Suchbaum	Im Durchschnitt $\log(n)$	Abhängig von der Eingabe	Zufall, Gesetz der großen Zahlen
2-3-4 Baum	$\log(n)$	perfektbalanziert	Split, Verschmelzen, Verschieben

### Ziel

Erstellen eines Schlüsselbaumes für eine große Anzahl von Elementen




### Problem

Hauptspeicher zu klein

### Lösung

Speicherung der Knoten auf dem Externspeicher (Platte)

Hauptspeicher





## Ansatz

Referenzieren eines Knotens entspricht Zugriff auf die Platte

Bei Aufbau eines binären Schlüsselbaumes für eine Datenmenge von z.B. einer Million Elementen ist die durchschnittliche Baumhöhe  $\log_2 10^6 \approx 20$ , d.h. 20 Suchschritte  $\rightarrow$  20 Plattenzugriffe

## Dilemma


Unterschied Aufwand Hauptspeicher- zu Plattenzugriff Faktor 10.000 (SSD) bis 100.000 (HD)

milli- zu nano-Sekunden (z.B. 60 ns zu 0,25-9ms)

Jeder Suchschritt benötigt einen Plattenzugriff  $\Rightarrow$  hoher Aufwand an Rechenzeit

## Lösung

Zerlegung des binären Baumes in Teilbäume, diese in sog. *Seiten* (*pages*) speichern



⇒ Mehrwegbaum (multiway-tree)

Intervallbasierte Suchdatenstruktur

Bei 100 Knoten pro Seite für 1 Million Elemente nur mehr  $\log_{100} 10^6 = 3$   
Seitenzugriffe

Im schlimmsten Fall (lineare Entartung) aber immer noch  $10^4$  Zugriffe ( $10^6 / 100$ )



## Knoten entsprechen Seiten (Blöcke)

besitzen eine Größe, Seitengröße (Anzahl der enthaltenen Einträge bzw. Speichergröße in Bytes)


repräsentieren die Transfereinheit zwischen Haupt- und Externspeicher

Zur Effizienzsteigerung des Transfers wird die Größe der Seiten an die Blockgröße der Speichertransfereinheiten des Betriebssystems angepaßt (Unit of Paging/Swapping)

Hauptspeicher




Externspeicher



## Indexstruktur besteht aus Schlüsselteil (Index) und Datenteil

### Graphische Struktur



### Index

ermöglicht den effizienten Zugriff auf die Daten

### Daten

enthalten die gespeicherte Information (vergleiche externe Knoten)

## 2 Knotenarten

### Indexknoten

Erlauben effizienten Zugriff auf die externe Knoten

Definieren die Intervallbereiche der Elemente, die im zugeordneten Teilbaum gespeichert sind.

realisiert durch interne Knoten

### Externe Knoten


Enthalten den durch Schlüssel identifizierten **Datensatz (key, info)**

vergl. mit **Dictionary**

realisiert durch Blattknoten

Im Beispiel verwenden wir nur Schlüsselwert, repräsentiert aber ganzen Datensatz

### Beispiel



### Höhenbalanzierter (perfektbalanzierter) Mehrwegbaum

#### Eigenschaften

- Externspeicher-Datenstruktur

  - Eine der häufigsten Datenstrukturen in Datenbanksystemen

- Dynamische Datenstruktur (Einfügen und Löschen)

- Algorithmen für Einfügen und Löschen erhalten die Balanzierungseigenschaft

- Garantiert einen begrenzten (worst-case) Aufwand für Zugriff, Einfügen und Löschen

- Der Aufwand für die Operationen Zugriff, Einfügen und Löschen ist bedingt durch die Baumstruktur von der Ordnung  $\log n$  ( $O(\log n)$ )

- Besteht aus Index und Daten


- Der Weg zu allen Daten ist gleich lang

Alle Blattknoten haben die gleiche Tiefe (gleiche Weglänge zur Wurzel)  
Die Wurzel ist entweder ein Blatt oder hat mind. 2 und max.  $2k+1$  Kinder  
Jeder (interne) Knoten besitzt mindestens  $k$  und maximal  $2k$  Schlüsselwerte, daher mindestens  $k+1$  und maximal  $2k+1$  Kinder

Für jeden Indexeintrag gilt, dass im linken Unterbaum nur Werte gespeichert sind, die kleiner sind als der Indexeintrag und im rechten Unterbaum nur Werte, die größer oder gleich dem Indexeintrag sind.

Intervallbasierte Suchdatenstruktur


Beispiel: B+-Baum der Ordnung 2



Jeder Indexknoten hat mindestens 2 und maximal 4 Schlüsselwerte und folglich mindestens 3 und maximal 5 Kinder

Ausnahme ist die Wurzel, kann auch nur 1 Schlüsselwert mit 2 Kindern enthalten



Die Größe der externen Knoten ist eigentlich durch die Ordnung nicht definiert, wird aber üblicherweise in der Literatur gleichgesetzt



## Suchen eines Datensatzes mit gegebenem Schlüssel

Datensatz mit Schlüssel 17

Datensatz mit Schlüssel 27



## Aufwand der Suche

Höhe eines B<sup>+</sup>-Baumes der Ordnung  $k$  mit *Datenblockgröße*  $b$  (mind.  $b$ , max  $2b$  Elemente) ist maximal  $\log_{k+1}(n/b)$ .

## Bereichsabfrage möglich


Suche alle Elemente im Bereich [Untergrenze, Obergrenze]



Einfügen bedeutet hier, dass ein Datensatz mit identifizierenden Schlüssel in einen externen Knoten eingefügt wird, wodurch gegebenenfalls Indexeinträge angepasst werden müssen

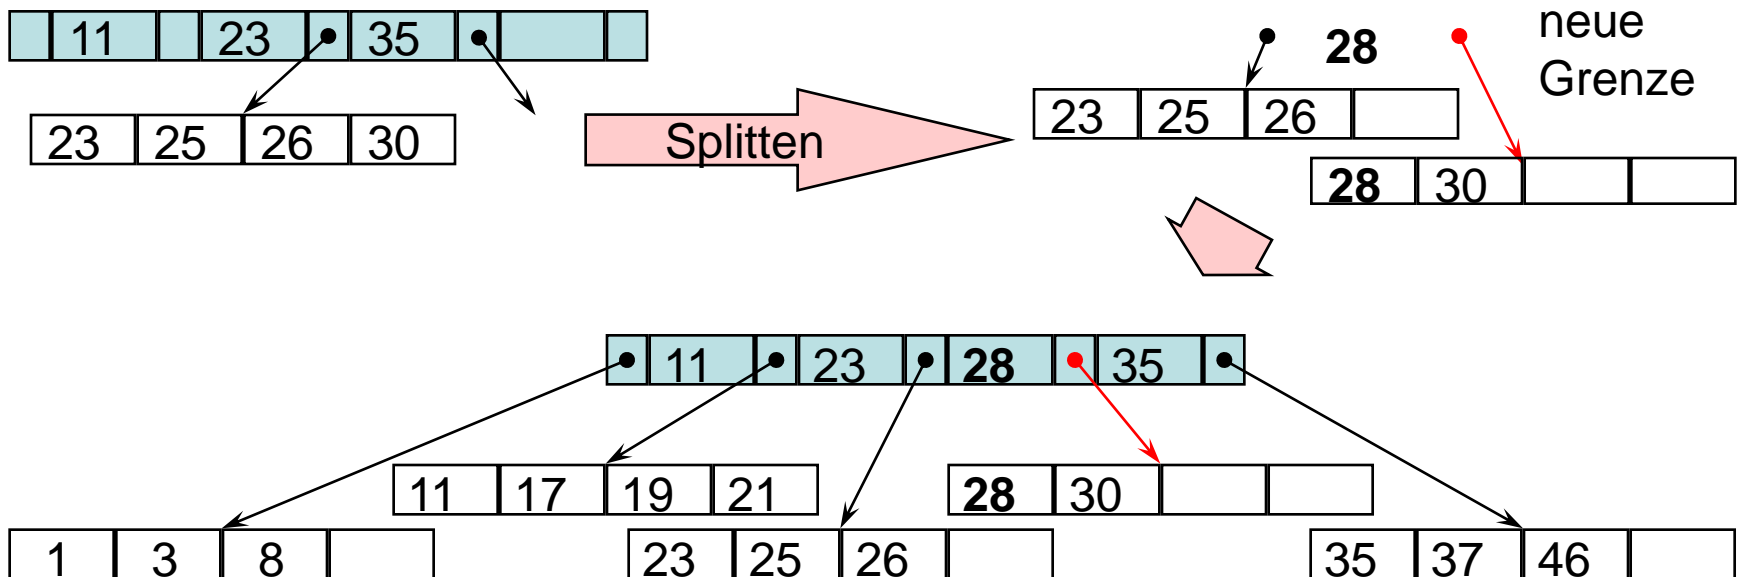
## Fall 1: Einfügen Datensatz mit Schlüssel 26

Platz im externen Knoten vorhanden, einfaches Einfügen




## Fall 2: Einfügen Datensatz mit Schlüssel 28

Kein Platz mehr im externen Knoten (**Überlauf, Overflow**),  
externer Knoten muss geteilt werden  $\Rightarrow$  **Split**




## Fall 3: Einfügen Datensatz mit Schlüssel 18

Kein Platz mehr im Knoten und kein Platz mehr im darüber liegenden Indexknoten, Indexknoten muss gesplittet werden




Beim Splitten eines Indexknoten wird das mittlere Indexelement im darüberliegenden Indexknoten eingetragen. Falls der nicht existiert (*Wurzelsplit*), wird eine neue Wurzel erzeugt



Der resultierende Baum hat folgendes Aussehen

webAD



## Unterscheidung des Splits für externe und interne Knoten


Externe Knoten:  $2k+1$  Elemente werden auf 2 benachbarte externe Knoten aufgeteilt

Interne Knoten:  $2k+1$  Indexelemente (Schlüsselwerte) werden auf 2 benachbarte Indexknoten zu je  $k$  Elemente aufgeteilt, das mittlere Indexelement wird in die darüberliegende Indexebene eingetragen.

Falls keine darüberliegende Ebene existiert, wird eine neue Wurzel erzeugt, der Baum wächst um eine Ebene ("Baum wächst von den Blättern zur Wurzel"), der Zugriffsweg zu den Daten erhöht sich um 1.

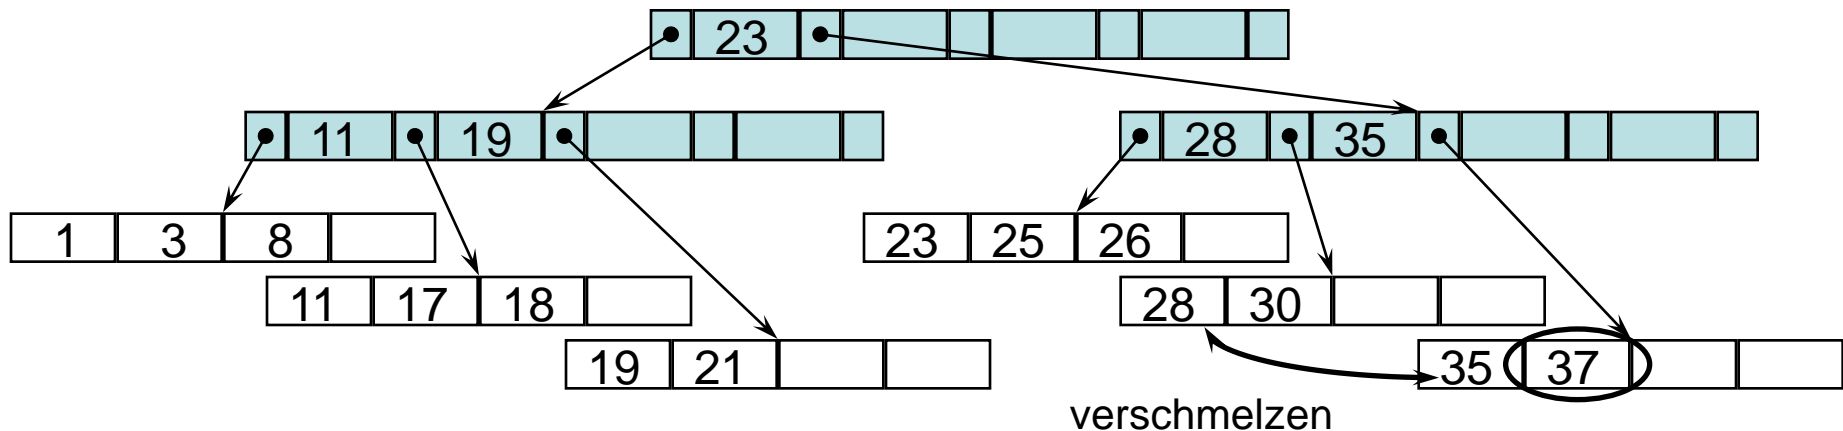
## Fall 1: Entfernen von Datensatz mit Schlüssel 46

Externer Knoten nach Löschen nicht unterbesetzt



## Fall 2: Entfernen von Datensatz mit Schlüssel 37


Externer Knoten nach dem Löschen unterbesetzt



Element wird entfernt, ist Knoten unterbesetzt (**Underflow**), Elementanzahl < k


Umgekehrter Vorgang zum Split  $\Rightarrow$  benachbarte Knoten werden **verschmolzen**

(Merge)



Interner Knoten unterbesetzt, muss ebenfalls mit Nachbarn verschmolzen werden.

Das Verschmelzen kann zur Verringerung der Baumhöhe führen, 2 Knoten werden zur neuen Wurzel verschmolzen, alte Wurzel wird entfernt.






## Anmerkung


Das Verschmelzen zweier Knoten kann zu einem Überlauf (analog Einfügen) des neuen Knoten führen, was einen nachfolgenden Split notwendig macht.

## Beispiel: (Baumausschnitt)



Diese (Verschmelzen-Splitten) Sequenz erzeugt eine besseren Aufteilung der Datensätze zwischen benachbarten Knoten. Dies wird auch hier (siehe 2-3-4 Baum, eigentlich fälschlicherweise) als Datensatzverschiebung (shift) bezeichnet.

In der Praxis werden die externen Knoten (Datenblöcke) linear verkettet, um einen effizienten, sequentiellen Zugriff in der Sortierreihenfolge der gespeicherten Elemente zu ermöglichen



## Datenverwaltung

Einfügen und Löschen unterstützt

## Datenmenge

unbeschränkt

abhängig von der Größe des vorhandenen Speicherplatzes

## Modelle

### **Externspeicherorientiert**

Unterstützung komplexer Operationen

Bereichsabfragen, Sortierreihenfolge

Speicherplatz	$O(n)$
Split, Verschmelzen	$O(1)$
Zugriff	$O(\log n)$
Einfügen	$O(\log n)$
Löschen	$O(\log n)$
Sortierreihenfolge	$O(n)$

} Garantiert!

Bitte beachten: Ordnung des Baumes ist konstanter Faktor!

Aufgrund dieser Eigenschaften und der Fokussierung auf externe Speichermedien ist der B+ -Baum sehr gut für den **Einsatz in Datenbanksystemen** geeignet

### Ein Trie ist ein digitaler Suchbaum oder Präfixbaum

Dient zur Speicherung und Suche von Zeichenketten

Verwaltung von Wörterbüchern, Telefonbüchern, Spellcheckern, etc.

Bezeichnung wird abgeleitet von “retrieval”, wird aber wie “try” ausgesprochen

Bei  $k$  Buchstaben ein “ $k+1$ -ary Tree”, wobei jeder Knoten durch eine Tabelle mit  $k+1$  Kanten auf Kinder repräsentiert wird

Ein Pfad beginnend bei der Wurzel bis zu einem Blatt im Trie stellt eine Zeichenkette dar

Kann im weitesten Sinn auch als Intervallbasierte Suchdatenstruktur interpretiert werden, da Intervalle  $[A, B[$ ,  $[B, C[$ , ...




Spezialformen

Patricia Tree, de la Briandais Tree

## Trie

TEN  
THE  
THEN  
THIN  
THIS  
TIN  
SING  
PIN  
WIN



Einfügen




Suchen



## Practical Algorithm to Retrieve Information Coded in Alphanumeric

Ziel ist die Komprimierung des Tries

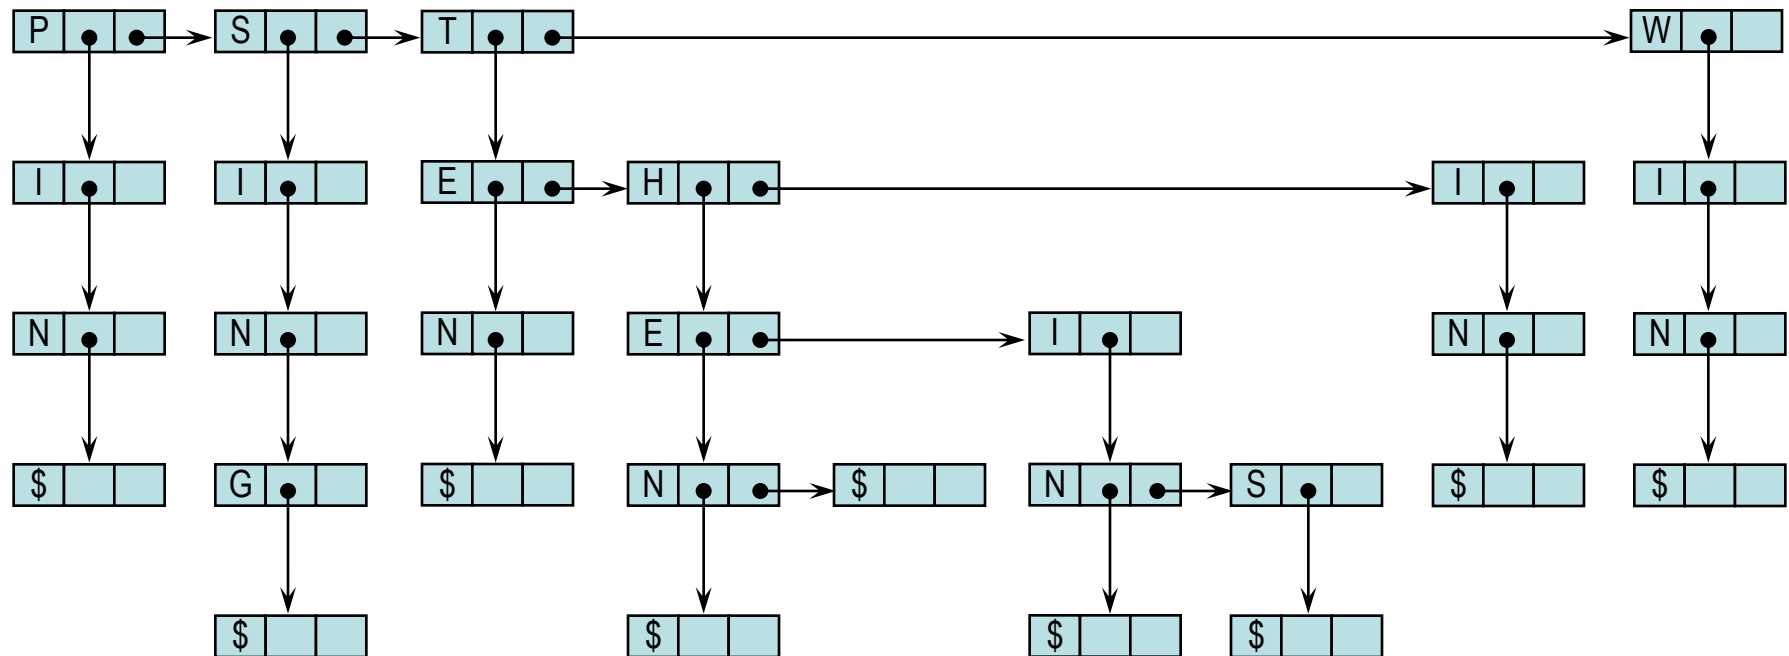


## Listen-Repräsentation eines Tries

statt der Tabellen im Knoten lineare Liste

Knoten besteht aus 2 Kinderkomponenten

Nächster Wert - Nächster Level





## Datenverwaltung

Einfügen und Löschen unterstützt

Struktur des Tries unabhängig von der Einfügereihenfolge

## Datenmenge

unbeschränkt

## Modelle

Hauptspeicherorientiert

Unterstützung komplexer Operationen


Bereichsabfragen, Sortierreihenfolge

## Laufzeit

Speicherplatz	$O(n)$
Zugriff	$O(\log n)$
Einfügen	$O(\log n)$
Löschen	$O(\log n)$
Sortierreihenfolge	$O(n)$

Bei der exakten Berechnung ist die Basis des Logarithmus abh. von der Kardinalität der Zeichenmenge, z.B. 26 (Grossbuchstaben), 2 (Bitstrings)

Datenstruktur zum wiederholten  
Finden und Entfernen des Elementes  
mit dem kleinsten (bzw. größten)  
Schlüsselwert aus einer Menge



### Anwendungen

Simulationssysteme (Schlüsselwerte repräsentieren Exekutionszeiten von Ereignissen)

Prozessverwaltung (Prioritäten der Prozesse)

Numerische Berechnungen (Schlüsselwerte entsprechen den Rechenfehlern, wobei zuerst die großen beseitigt werden)

Grundlage für eine Reihe komplexer Algorithmen (Graphentheorie, Filekompression, etc.)

Anmerkung: Im folgenden betrachten wir o.B.d.A. nur Priority Queues die den Zugriff auf die kleinsten Elemente unterstützen

## Construct

Erzeugen einer leeren Priority Queue

## IsEmpty

Abfrage auf leere Priority Queue

## Insert

Einfügen eines Elementes

## FindMinimum

Zurückgeben des kleinsten Elementes

## DeleteMinimum

Löschen des kleinsten Elementes

## Ungeordnete Liste

Elemente werden beliebig in die Liste eingetragen (Aufwand  $O(1)$ ).

Beim Zugriff bzw. Löschen des 'kleinsten' Elementes muss die Liste abgesucht werden Aufwand  $\rightarrow O(n)$ .


## Geordnete Liste

Elemente werden in der Reihenfolge ihrer Größe eingetragen (Aufwand  $O(n)$ ).

Zugriff bzw. Löschen konstanter Aufwand  $\rightarrow O(1)$

## Problem

Aufwand  $O(n)$  schwer zu vermeiden.



## Balanzierte Schlüsselbäume

Einfügen im balanzierten Schlüsselbaum vom Aufwand  $O(\log n)$

Zugriff realisieren durch Verfolgen des äußersten linken Weges im Baum  
(zum kleinsten Element)  $\rightarrow$  Aufwand  $O(\log n)$


## Günstigste Realisierung über ungeordnete, komplette Schlüsselbäume

mit der Eigenschaft, dass für alle Knoten die Schlüsselwerte ihrer  
Nachfolger größer (oder kleiner) sind



Wertemenge

3 6 5 10 9 11



### Heap

Ungeordneter, binärer, kompletter Schlüsselbaum

Wert jedes Knotens ist kleiner (größer) oder gleich den Werten seiner Nachfolgerknoten

Wurzel enthält kleinstes (größtes) Element


Anordnung der Unterbäume bez. ihrer Wurzel undefiniert (ungeordneter Baum)

## Realisierung eines Heaps effizient durch ein Feld


Die  $n$  Schlüsselwerte des Heaps können als Folge von Elementen  $x_0, x_1, x_2, \dots, x_{n-1}$  interpretiert werden, wobei die Position der einzelnen Knotenwerte im Feld durch folgende Regel bestimmt wird:

Wurzel in Position 0, die Kinder des Knotens  $i$  werden an Position  $2i+1$  und  $2i+2$  gespeichert.

### Beispiel



Zugriff auf das kleinste Element mit konstantem Aufwand:  $O(1)$   
→ Wurzel = erstes Element im Feld.





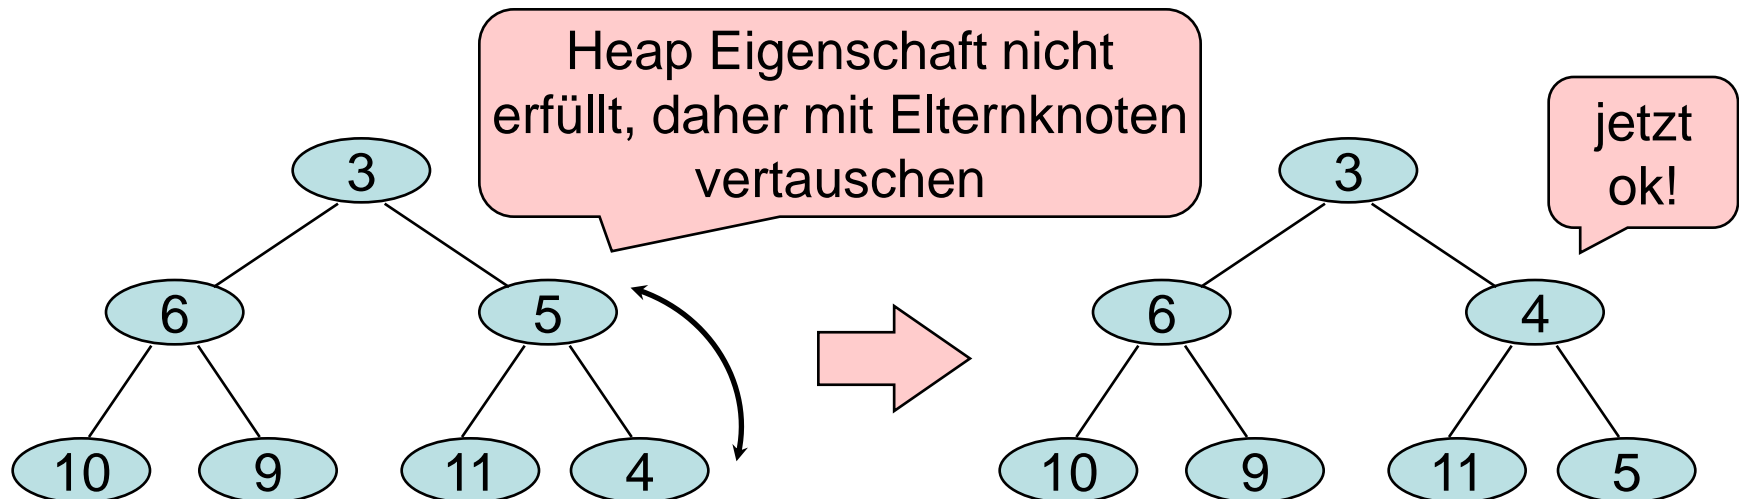
```
class PQ {  
    int *a, N;  
public:  
    PQ(int max) { a = new int[max]; N = -1; }  
    ~PQ() { delete[] a; }  
    int FindMinimum(){ return a[0]; }  
    int IsEmpty() { return (N == -1); }  
    void Insert(int);  
    int DeleteMinimum();  
    ...  
};
```

Neues Element an der letzten Stelle im Feld eintragen  
Überprüfen, ob die Heap Eigenschaft erfüllt ist  
Wenn nicht, mit Elternknoten vertauschen und solange  
wiederholen bis erfüllt

Eintragen von 4





(an der letzten Stelle im Feld)

Aufwand:  $O(\log n)$



```
void PQ::Insert(int v) {  
    int child, parent;  
    a[++N] = v;  
    child = N;  
    parent = (child - 1)/2;  
    while(child != parent) {  
        if(a[parent] > a[child]) {  
            swap(a[parent], a[child]);  
            child = parent;  
            parent = (parent - 1)/2;  
        } else break; // to stop the loop  
    }  
}
```

Wurzel mit äußerst rechten Blattknoten tauschen, diesen Blattknoten löschen, Wurzel in den Baum sinken lassen (mit kleinerem Kindknoten vertauschen), bis Heap Eigenschaft gilt.  
Aufwand:  $O(\log n)$



```
int PQ::DeleteMinimum() {
    int parent = 0, child = 1;
    int v = a[0];
    a[0] = a[N];
    N--;
    while(child <= N) {
        if(a[child] > a[child+1]) child++;
        if(a[child] < a[parent]) {
            swap(a[parent], a[child]);
            parent = child;
            child = 2*child + 1;
        } else break; // to stop the loop
    }
    return v;
}
```

## Datenverwaltung

Einfügen und Löschen unterstützt

## Datenmenge

unbeschränkt

## Modelle

Hauptspeicherorientiert

Nur simple Operationen

## Laufzeit

Speicherplatz	$O(n)$
Zugriff (Minimum/Maximum)	$O(1)$
Einfügen	$O(\log n)$
Löschen	$O(\log n)$


Der Heap stellt eine effiziente Basisdatenstruktur für viele weitere darauf aufbauende Datenstrukturen dar

Bitte zu unterscheiden! Der Begriff Heap wird in der Informatik zur Bezeichnung verschiedener Konzepte verwendet

Heap als Datenstruktur zur Speicherung von Priority Queues



Heap als Speicherbereich zur Verwaltung (vom Benutzer selbst verwalteter) dynamisch allozierter Speicherbereiche

Heap als Speicherform in Datenbanken






Eine Heap (Priority Queue) kann Basis zum Sortieren bilden  
(Williams 1964):

1. ein Element nach dem anderen in einen Heap einfügen
2. sukzessive das kleinste bzw. größte Element entfernt  
die Element werden in aufsteigender bzw. absteigender Ordnung geliefert









Kombination der beiden Arrays, Vermeidung von doppeltem Speicherplatz



Heap-Eigenschaft umdrehen: Wert jedes Knotens ist größer oder gleich den Werten seiner Kinderknoten




# Beispiel: buildheap




Wertemenge

9 6 5 10 3 11


9	6	5	10	3	11
0	1	2	3	4	5




Idee: Heap-Eigenschaft erzeugen; für Blattknoten trivialerweise erfüllt  
Nr. 2 erster zu prüfender Knoten, 11 passt nicht, in Baum sinken lassen, d.h. 5 mit 11 tauschen



Wert 6 (Nr. 1) passt nicht, in Teilbaum sinken lassen, d.h. mit größerem der Nachfolger vertauschen, d.h. 6 mit 10









Nr. 0 (9) in Baum sinken.



Heap-Eigenschaft erfüllt!

11	10	9	6	3	5
0	1	2	3	4	5

Idee: Maximum "löschen" und am freiwerdenden Platz sichern



```
void Vector::Heapsort() {
    int heapsize = Length();
    BuildMaxheap();
    for(int i = Length()-1; i >= 1; i--) {
        swap(a[0], a[i]);
        heapsize--;
        heapify(0, heapsize);
    }
}

void Vector::BuildMaxheap() {
    for(int i = Length()/2 - 1; i >= 0; i--)
        heapify(i, Length());
}
```

```
void Vector::heapify(int i, int heapsize) {
    int left = 2*i + 1;
    int right = 2*i + 2;
    int largest;
    if (left < heapsize && a[left] > a[i])
        largest = left;
    else
        largest = i;
    if (right < heapsize && a[right] > a[largest])
        largest = right;
    if (largest != i) {
        swap(a[i], a[largest]);
        heapify(largest, heapsize);
    }
}
```

## Quicksort

Entartung zu  $O(n^2)$  möglich

Wahl des Pivotelements!

## Mergesort

immer Laufzeit  $O(n \cdot \log(n))$

doppelter Speicherplatz notwendig

## Heapsort

keinen der obigen Nachteile

aber höherer konstanter Aufwand

## Baumstrukturen

- Notation

- spez. Eigenschaften, von  $O(n)$  auf  $O(\log n)$

## Suchbäume

- Binäre Suchbäume

- AVL-Bäume

- 2-3-4 Bäume

- B<sup>+</sup>-Baum

- Balanzierung

## Trie

## Priority Queues

- Heap